Санкт-Петербургский государственный политехнический университет Институт компьютерных наук и технологий

«Высшая школа программной инженерии»

Санкт-Петербург

2020

КУРСОВАЯ РАБОТА

По дисциплине «Технология использования гибридных суперкомпьютеров для обработки больших данных»

Выполнил

20

Каравашкин Л.А.

3540904/00202

Преподаватель Левченко А.В

Цель работы

Цель работы - программное обеспечение, разработанное по технологиям многоязыкового и параллельного программирования и задействующее современную целевую архитектуру.

Задачи

- 1. Разработать техническое задание на программное обеспечение.
- 2. Разработать динамически подключаемый код по обработке данных.
 - а. Разработать однопоточный невекторизованный код.
 - b. Разработать однопоточный векторизованный код.
 - с. Разработать многопоточный невекторизованный код.
 - d. Разработать многопоточный векторизованный код.
- 3. Разработать головную программу.
- 4. Провести сравнительный анализ.

Ход работы

Выбор технического задания

В качестве функции, к которой будет применяться оптимизация, была выбрана функция для поэлементного сложения значений трех массивов.

Языком для внешней библиотеки был выбран c++, а для головной программы был выбран Python.

Разработка библиотеки на с++

Для всех функций был добавлен ключ -O0 для того, чтобы отключить стандартные оптимизации языка.

1. Однопоточный невекторизованный код:

```
#pragma GCC optimize("-O0")
long long CalcSimple(float * a, float * b, float * c, float * resArr, int n) {
  auto start = std::chrono::high_resolution_clock::now();
  for (int i = 0; i < n; i++) {
    resArr[i] = a[i] + b[i] + c[i];
  }
  auto finish = std::chrono::high_resolution_clock::now();
  return std::chrono::duration_cast < std::chrono::nanoseconds > (finish - start).count();
}
```

Простой цикл без оптимизации.

Функция принимает 4 массива, 3 из которых для сложения и 1 для сохранения результата.

В выходном значении передается время выполнения функции.

2. Однопоточный векторизованный код

```
#pragma GCC optimize ("-O0")
long long CalcVect(float * a,float * b, float * c, float* resArr , int n) {
    auto start = std::chrono::high_resolution_clock::now();
    #pragma omp simd
    for(int i=0;i<n;i++) {
        resArr[i] = a[i]+b[i]+c[i];
    }
    auto finish = std::chrono::high_resolution_clock::now();
    return std::chrono::duration_cast<std::chrono::nanoseconds>(finish-start).count();
}
```

pragma omp simd указывает компилятору применить к циклу векторизацию.

3. Многопоточный невекторизованный код

```
#pragma GCC optimize ("-O0")
long long CalcParallel(float * a,float * b, float * c, float* resArr , int n) {
  auto start = std::chrono::high_resolution_clock::now();
  #pragma omp parallel for
```

```
for(int i=0;i<n;i++) {
    resArr[i] = a[i]+b[i]+c[i];
}
auto finish = std::chrono::high_resolution_clock::now();
return std::chrono::duration_cast<std::chrono::nanoseconds>(finish-start).count();
}
```

pragma omp parallel for указывает компилятору распараллелить цикл по нескольким потокам. Так как отсутствует зависимость по данным между итерациями, то это должно увеличить скорость выполнения.

4. Многопоточный векторизованный код

```
#pragma GCC optimize ("-O0")
long long CalcVectParallel(float * a,float * b, float * c, float* resArr , int n) {
   auto start = std::chrono::high_resolution_clock::now();
   #pragma omp parallel for simd
   for(int i=0;i<n;i++) {
      resArr[i] = a[i]+b[i]+c[i];
   }
   auto finish = std::chrono::high_resolution_clock::now();
   return std::chrono::duration_cast<std::chrono::nanoseconds>(finish-start).count();
}
```

pragma omp parallel for simd - одновременной использование векторизации и распараллеливания цикла по потокам.

5. Сборка библиотеки

```
g++ -fopenmp -fPIC -c -o clib clib.cpp
g++ -shared -lgomp -fopenmp -o clib.so clib
```

Разработка головной программы

1. Организация работы с библиотекой

```
Подключение библиотеки: lib = ctypes.CDLL('./clib.so')
```

Адаптер функций для библиотеки:

Адаптер принимает функцию вида lib.function_name и размер массива с которым функции нужно работать и возвращает функцию python.

2. Описание программы

Тело программы представляет из себя применение библиотечных функций, сбор статистики зависимости времени выполнения функций от количества элементов в массивах и валидацию результатов за счет нескольких циклов и подсчета средних значений времени.

При запуске программа предлагает пользователю выбрать максимальное количество элементов в массивах и количество циклов валидации. После выполнения пользователю выводится время выполнения функций для выбранного количества элементов, а также графики зависимости времени от количества элементов и времени на один элемент от количества элементов.

3. Запуск программы

python3 main.py

Результат

После выполнения программы для максимального количества элементов в массиве равным 5 000 000 и 5 циклов валидации получены следующий графики:




Рис 1.Зависимость времени выполнения функций от размера массива




Рис 2. Зависимость времени обработки одного элемента массива от размера массива.

По графикам видно, что до одного миллиона значений в массиве методы использующие параллельность только замедляют выполнение функции, однако при достаточном размере массива эти методы доказывают свою эффективность.

Векторизация в сравнении с функцией без нее показывает переменные результаты в зависимости от размера массива.

Вывод

В ходе работы было написано многоязыковое программное обеспечение, в котором за тяжелые вычисления отвечала написанная нами библиотека на C++, а за организацию работы и вывод статистики отвечало приложение на Python.

Было продемонстрировано использование методов оптимизации вычислений с использованием орептр в функции для поэлементного сложения массивов.

Также было проведено сравнение эффективности этих методов оптимизации: при достаточно большом значении элементов в массиве наиболее эффективны методы с использование параллельного выполнения в нескольких потоках, однако в ином случае скорость работы снижается. Векторизация в полученных результатах имела переменную эффективность и абсолютные значения времени выполнения были соразмерны функции без векторизации.